

EDA, Preprocessing, Regresi Linear
Dataset Medical Cost Personal

EKSPLORASI DATA ASURANSI

Machine Learning

Maddinatul Dzahra Aulia Gusman INF 5C

A • MEMUAT DATA

ISI DATA MEMUAT:

File dibaca : insurance.csv

Ukuran data : (1338, 7) (baris, kolom)

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16,884.924
1	18	male	33.770	1	no	southeast	1,725.552
2	28	male	33.000	3	no	southeast	4,449.462
3	33	male	22.705	0	no	northwest	21,984.471
4	32	male	28.880	0	no	northwest	3,866.855
5	31	female	25.740	0	no	southeast	3,756.622
6	46	female	33.440	1	no	southeast	8,240.590
7	37	female	27.740	3	no	northwest	7,281.506
8	37	male	29.830	2	no	northeast	6,406.411
9	60	female	25.840	0	no	northwest	28,923.137

```
>>> df.shape
```

```
(1338, 7)    (baris, kolom)
```

| 1.338 orang pemegang polis asuransi kesehatan di AS

| Target: charges (biaya, USD)

| Fitur: age, sex, bmi, children, smoker, region

B.1 • STRUKTUR DATA

Tipe data tiap kolom

```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype  
---  -
 0   age         1338 non-null   int64  
 1   sex         1338 non-null   str     
 2   bmi         1338 non-null   float64 
 3   children    1338 non-null   int64  
 4   smoker      1338 non-null   str     
 5   region      1338 non-null   str     
 6   charges     1338 non-null   float64 
dtypes: float64(2), int64(2), str(3)
memory usage: 73.3 KB
```

Semua kolom 1.338 non-null, tidak ada data kosong

3 kolom teks (sex, smoker, region), harus di-encoding dulu
 biar bisa masuk model

age dan children bertipe int, bmi dan charges bertipe float

B.2 · STATISTIK DESKRIPTIF

CHARGES: RATA-RATA JAUH DI ATAS MEDIAN

	count	mean	std	min	25%	50%	75%	max
age	1,338.000	39.207	14.050	18.000	27.000	39.000	51.000	64.000
bmi	1,338.000	30.663	6.098	15.960	26.296	30.400	34.694	53.130
children	1,338.000	1.095	1.205	0.000	0.000	1.000	2.000	5.000
charges	1,338.000	13,270.422	12,110.011	1,121.874	4,740.287	9,382.033	16,639.913	63,770.428

39 tahun
rata-rata usia (18 sampai 64)

30,7
rata-rata BMI, pas batas di
obesitas (30)

13.270 vs 9.382
mean vs median charges, miring
ke kanan

B.3 • KUALITAS DATA

Data kosong dan duplikat

Missing value per kolom:

```
age      0
sex      0
bmi      0
children 0
smoker   0
region   0
charges  0
dtype: int64
```

Jumlah baris duplikat : 1

Baris yang duplikat:

	age	sex	bmi	children	smoker	region	charges
195	19	male	30.590	0	no	northwest	1,639.563
581	19	male	30.590	0	no	northwest	1,639.563


| Missing value: 0 di semua kolom

| Duplikat: 1 baris (baris 195 dan 581 kembar)

| Nggak perlu imputasi, tinggal buang duplikatnya
di tahap preprocessing

B.4 • SEBARAN VARIABEL NUMERIK

Bentuk distribusi tiap variabel



➤ age: merata dari 18 sampai 64 tahun


➤ bmi: mirip lonceng, rata-rata sekitar 30,7

➤ children: kebanyakan 0 sampai 2 anak

➤ charges: miring ke kanan (skew 1,52). Banyak yang murah, sedikit yang mahal banget

B.5 CHARGES PER KATEGORI

Perokok bikin biaya jauh lebih mahal




➤ Perokok rata-rata 32.050 vs non-perokok 8.434, sekitar 3,8 kali lipat

➤ sex dan region: bedanya kecil, kotaknya banyak yang numpuk

➤ children: polanya naik turun, pengaruhnya lemah

B.6 SCATTER PLOT

Biaya terpisah jadi tiga pita




Usia naik, biaya ikut naik di semua pita

Usia naik, biaya ikut naik di semua pita

BMI 30 ke atas cuma bikin loncat kalau perokok

B.7 PEROKOK × OBESITAS

Obesitas bahayanya cuma buat perokok



+11%


kalau obesitas tapi non-perokok (7.977 jadi 8.843)

+95%

kalau obesitas dan perokok (21.363 jadi 41.558)

B.8 KORELASI

Smoker paling nempel sama charges



smoker 0,79: kuat banget

age 0,30 dan **bmi 0,20:** lemah

children 0,07 dan **sex 0,06:** hampir nol

Antar fitur nggak saling nempel,
jadi aman buat regresi

C.1 DAN C.2 • PREPROCESSING

Hapus duplikat dan encoding

	age	sex	bmi	children	smoker	charges	region_northwest	region_southeast	region_southwest
0	19	0	27.900	0	1	16,884.924	0	0	1
1	18	1	33.770	1	0	1,725.552	0	1	0
2	28	1	33.000	3	0	4,449.462	0	1	0
3	33	1	22.705	0	0	21,984.471	1	0	0
4	32	1	28.880	0	0	3,866.855	1	0	0

Sebelum: (1338, 7)
Sesudah: (1337, 7)
Missing value: 0

Duplikat dibuang: 1.338 jadi 1.337 baris
sex dan smoker jadi 0/1
region jadi one-hot, northeast jadi acuan

C.3 DAN C.4 • PREPROCESSING

Split dulu, baru scaling

```
X_train: (1069, 8) | X_test: (268, 8)
```

```
Proporsi perokok -> train: 0.205 | test: 0.205
```

Rata-rata & std data latih setelah scaling:

	age	bmi	children
mean	-0.000	-0.000	-0.000
std	1.000	1.000	1.000

Rata-rata & std data uji setelah scaling (tidak harus 0 dan 1):

	age	bmi	children
mean	0.057	-0.132	0.021
std	0.999	1.007	1.098

Split 80/20: 1.069 latih, 268 uji

Stratify smoker: proporsi perokok sama (20,5%)

Scaler di-fit dari data latih aja, jadi latih mean 0 dan std 1

Data uji nggak persis 0 dan 1, itu wajar (anti data leakage)

D.1 • REGRESI LINEAR

Intercept dan koefisien

Intercept (b_0): -11593.79

	fitur	koefisien
0	smoker	23,750.032
1	region_southeast	-1,193.734
2	region_southwest	-1,031.822
3	children	626.134
4	region_northwest	-361.197
5	bmi	330.832
6	sex	-257.961
7	age	255.925

smoker +23.750: perokok kira-kira 23,7 ribu USD lebih mahal

age +256 per tahun, **bmi +331** per poin, **children +626** per anak

region dibaca relatif ke northeast, selisihnya kecil

Intercept –11.594: cuma titik awal garis, nggak ada makna nyata

D.2 · EVALUASI MODEL

Seberapa bagus modelnya?

Metrik	Nilai
R ² train	0.733
R ² test	0.820
MSE	25,876,347
RMSE	5,086.88
MAE	3,592.79


R² test 0,82: model jelasin sekitar 82% variasi biaya

RMSE sekitar 5.087 USD: meleset sekitar 39% dari rata-rata biaya

R² test (0,82) > R² train (0,73), kemungkinan data uji kebetulan lebih gampang

D.3 · ANALISIS RESIDUAL

Residualnya masih berpola



Residual tidak acak. Perokok terpecah jadi dua gugus

Ada yang kemahalan dan ada yang kemurahan prediksinya

Histogram bukan lonceng, Q-Q plot melengkung, residual nggak normal

Model masih terlalu simpel, belum nangkap interaksi perokok × obesitas

G • KESIMPULAN

1. **Merokok** faktor paling berpengaruh (korelasi 0,79, biaya sekitar 3,8 kali lipat)
2. **Preprocessing**: hapus duplikat, encoding, split, baru scaling
3. **Regresi linear**: R^2 test 0,82, RMSE sekitar 5.087 USD
4. **Residual masih berpola**, jadi perlu fitur interaksi perokok $\times$ obesitas. Di notebook, setelah ditambah fitur itu R^2 naik ke 0,92

THANK YOU