



**EDA, preprocessing,  
dan regresi linear  
pada data insurance.csv**

Nurkhotimah - 2488010017  
Machine Learning  
Informatika 5C



# Dataset dan kualitas data

**1.338**

baris data

**7**

kolom variabel

**0**


missing value

**1**

baris duplikat


- Fitur: age, sex, bmi, children, smoker, region; target: charges (biaya asuransi, USD)
- Satu baris duplikat (indeks 195 dan 581) dihapus, tersisa 1.337 baris bersih
- Rata-rata charges 13.270 dengan rentang 1.122 hingga 63.770

# Distribusi variabel numerik



- Skewness charges 1,52: sangat condong ke kanan
- children 0,94, bmi 0,28, age 0,06: relatif simetris
- Sekitar 10,4% outlier dipertahankan karena merupakan klaim medis nyata

# Perokok membayar jauh lebih mahal





**3,8x**

rasio rata-rata biaya perokok vs non-perokok

- Perokok: rata-rata 32.050
- Non-perokok: rata-rata 8.434
- Sex, region, dan jumlah anak tidak banyak membedakan biaya

# Korelasi terhadap charges



# Tahap preprocessing

1

## Encoding

sex dan smoker: label encoding 0/1. region: one-hot (drop\_first)

2

## Split 80:20

Train 1.069 baris, test 268 baris, stratifikasi smoker (proporsi 20,5% di keduanya)


3

## Scaling

StandardScaler hanya fit pada data latih untuk mencegah data leakage


*Scaling tidak mengubah  $R^2$  Regresi Linear (0,8205 pada skala asli maupun terskala), namun membuat koefisien dapat dibandingkan antar fitur.*

# Model baseline: koefisien regresi



- Status perokok menambah sekitar 23.750 pada prediksi biaya
- Intercept: -11.594
- Fitur lain berpengaruh jauh lebih kecil

# Evaluasi model baseline



**0,820**  
R<sup>2</sup> test


**5.087**  
RMSE test

**3.593**  
MAE test

**0,733**  
R<sup>2</sup> train

RMSE setara 39,2% dari rata-rata charges.  
Residual condong ke kanan (skewness 0,62):  
model kurang menangkap biaya perokok yang tinggi.

# Rekayasa fitur meningkatkan akurasi



- Fitur baru: usia kuadrat, status obesitas, interaksi obesitas x smoker
- Obesitas menaikkan biaya 11% pada non-perokok, tetapi 95% pada perokok
- Lasso setara:  $R^2$  0,922, RMSE 3.348

*RMSE turun sekitar 34% dan MAE sekitar 44%. Transformasi log target, model pohon, dan Ridge tidak memberi perbaikan dalam dolar.*

# Kesimpulan

- Merokok adalah penentu biaya terkuat (korelasi 0,79; biaya 3,8x lipat), diikuti usia dan BMI.
- Interaksi BMI dan merokok krusial: obesitas pada perokok melonjak 95% biayanya.
- Rekayasa fitur menaikkan  $R^2$  dari 0,820 menjadi 0,921 dan menurunkan RMSE dari 5.087 menjadi 3.372.
- Pelajaran inti: eksplorasi data dan fitur yang tepat lebih berpengaruh daripada sekadar mengganti algoritma.